



**UNIVERSIDADE FEDERAL DO AMAPÁ – UNIFAP
PRÓ-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
ESPECIALIZAÇÃO EM PROJETOS EM INTELIGÊNCIA
ARTIFICIAL**

JOSÉ MARCEL DE OLIVEIRA SANTOS

**PROJETO INTEGRADOR: PIPELINE END-TO-END DE
ENGENHARIA DE DADOS E MACHINE LEARNING**
Entrega Final P15

Macapá – AP
2026

JOSÉ MARCEL DE OLIVEIRA SANTOS

**PROJETO INTEGRADOR: PIPELINE END-TO-END DE ENGENHARIA DE
DADOS E MACHINE LEARNING**

Entrega Final P15

Documentação apresentada à disciplina de Banco de Dados para Engenharia de Dados, do curso de Especialização em Projetos em Inteligência Artificial da Universidade Federal do Amapá (UNIFAP), como requisito avaliativo do Projeto Integrador (P15).

Professor: Adolfo Francesco de Oliveira Colares

Macapá – AP
2026

Projeto Integrador (P15): Pipeline End-to-End de Engenharia de Dados e ML

Previsão de churn de clientes de um e-commerce, a partir de duas fontes de dados reais, armazenadas em PostgreSQL com modelagem relacional, processadas por um pipeline de ETL em Python, com engenharia de features e um modelo de classificação treinado e avaliado.

Fontes de Dados -> PostgreSQL -> ETL Python -> Features -> Machine Learning -> Métricas -> Resultados

Disciplina: Banco de Dados para Engenharia de Dados. Especialização em Projetos em Inteligência Artificial (UNIFAP). Professor: Adolfo Francesco de Oliveira Colares. Autor: Jose Marcel de Oliveira Santos.

Fontes de dados

1. Arquivo (CSV): data/clientes.csv e data/vendas.csv: cadastro de 420 clientes e histórico de vendas de um e-commerce (dados sintéticos, gerados por `etl/gen_fonte_csv.py`, com sujeira proposital: nulos, duplicatas e outliers, para o ETL ter o que limpar de verdade).
2. API pública (IBGE): `servicodados.ibge.gov.br`, consumida ao vivo em `etl/extract_ibge.py`: lista oficial de municípios do Brasil, usada para enriquecer cada cliente com município, UF e região geográfica oficiais a partir do nome da cidade cadastrada.

Modelagem no PostgreSQL

Esquema relacional (3FN) em `sql/schema.sql`:

`dim_cliente`: um registro por cliente, com FK para `dim_localidade`.
`dim_produto`: catálogo de produtos por categoria.
`dim_localidade`: município, UF e região, populada pela Fonte 2 (IBGE).
`fato_vendas`: uma linha por transação, FK para as três dimensões acima.

Pipeline de ETL (`etl/pipeline_etl.py`)

Extract: lê os dois CSVs da Fonte 1 e consulta a API do IBGE (Fonte 2) em tempo real.

Transform: remove duplicatas e linhas sem valor; remove outliers em `valor_total` pelo método IQR calculado por categoria de produto (um notebook de R\$4.000 e normal em Eletrônicos, mas pareceria outlier se comparado direto com livros de R\$50; o IQR global foi testado e descartado por remover compras legítimas); casa o nome da cidade de cada cliente com o índice de municípios do IBGE (100% de match neste dataset).

Load: grava tudo no PostgreSQL respeitando o esquema acima.

Log completo de cada execução em `logs/etl.log`.

Engenharia de features (`etl/feature_engineering.py`)

Lê os dados já modelados no PostgreSQL (não o CSV bruto) e aplica um split temporal para evitar vazamento de dados: um corte 90 dias antes da data mais recente separa o que vira feature (tudo até o corte) do que vira o rótulo (se o cliente comprou depois do corte).

18 features: agregacoes (total, quantidade e ticket medio de compras, categorias distintas), temporais (dias desde ultima e primeira compra, dias desde cadastro) e encoding one-hot (segmento, regioao do IBGE, categoria preferida). Documentacao de cada feature no notebook, secao 4.

Modelo (etl/treinar_modelo.py)

Tres modelos comparados com validacao cruzada (5-fold, F1) e avaliados em um conjunto de teste separado (20%, estratificado):

Modelo	Accuracy	F1	ROC-AUC
Random Forest (selecionado)	0,76	0,79	0,82
Gradient Boosting	0,72	0,75	0,84
Logistic Regression	0,66	0,70	0,66

StandardScaler ajustado somente no treino (sem vazamento). Modelo final salvo em models/modelo_churn.pkl (dicionario com modelo, scaler e colunas, via joblib).

Estrutura do repositorio

```
projeto_integrador_p15/
  data/                      (CSVs de origem e features.csv gerado)
  etl/
    gen_fonte_csv.py         (gera a Fonte 1, sintetica)
    extract_ibge.py          (consome a Fonte 2, API do IBGE)
    pipeline_etl.py          (ETL completo: extract, transform, load)
    feature_engineering.py
    treinar_modelo.py
  sql/
    schema.sql               (modelagem relacional do PostgreSQL)
  models/
    modelo_churn.pkl
  notebooks/
    projeto_integrador.ipynb  (notebook final, ja executado)
  logs/
    etl.log
```

Como reproduzir

```
pip install pandas numpy sqlalchemy psycopg2-binary requests scikit-learn
matplotlib seaborn joblib jupyter nbformat nbclient
```

```
# 1. Banco de dados
psql -U postgres -h localhost -c "CREATE DATABASE projeto_integrador_p15;"
psql -U postgres -h localhost -d projeto_integrador_p15 -f sql/schema.sql
```

```
# 2. Gerar a Fonte 1 (ou usar os CSVs ja versionados em data/)
python etl/gen_fonte_csv.py
```

```
# 3. Rodar o pipeline completo (ETL, features, modelo)
python etl/pipeline_etl.py
```

```
python etl/feature_engineering.py  
python etl/treinar_modelo.py
```

```
# 4. Ou simplesmente abrir e rodar o notebook, que ja encadeia tudo isso:  
jupyter nbconvert --to notebook --execute notebooks/projeto_integrador.ipynb
```

A string de conexao (postgresql://postgres:@localhost:5432/projeto_integrador_p15) esta definida em pipeline_etl.py e feature_engineering.py; ajuste se o PostgreSQL usar outro usuario, senha ou porta.

Decisoes tecnicas e limitacoes conhecidas

IQR por categoria, nao global: ver secao de ETL acima. Decisao tomada depois de testar a versao global e constatar que ela descartava vendas legitimas de categorias mais caras.

Split temporal em vez de aleatorio: a engenharia de features deste projeto corrige deliberadamente um problema de vazamento de dados identificado na atividade anterior do modulo (P14): la, a mesma variavel de recencia era usada como feature e como base do target, inflando as metricas artificialmente (F1 chegava a 1,0). Aqui, features e target vem de janelas de tempo disjuntas, e as metricas resultantes (F1 de aproximadamente 0,79) sao mais baixas, mas tambem mais confiaveis.

Dataset sintetico: os CSVs de origem sao gerados, nao sao dados reais de um e-commerce de verdade. A Fonte 2 (IBGE), porem, e totalmente real e consumida ao vivo via HTTP a cada execucao do ETL.